

Auditoría y prevención de fuga de datos en pipelines de Machine Learning generados por LLM

Witman Zavala Muñoz

Universidad de Las Américas

Facultad de Ingeniería y Negocios
Magíster en Ciencia de Datos

Capstone Project
Profesor Guía: Francisco Pérez
Profesor Co-guía: No aplica

Santiago de Chile, Octubre, 2026

RESUMEN

Los asistentes de programación basados en modelos de lenguaje grande (LLM) ya escriben pipelines de Machine Learning completos. Entre sus posibles errores, la fuga de datos es el único que no interrumpe la ejecución e infla las métricas de evaluación: un transformador (escalador, imputador, selector de variables) que se ajusta con todas las filas antes de separar entrenamiento y prueba produce un modelo que parece mejor de lo que es. Este informe presenta un auditor determinista que combina el análisis del árbol sintáctico (AST) con la verificación en ejecución, un refactorizador que repara los patrones habituales sin cambiar el modelo y un indicador de Sesgo de Optimismo ($\Delta\mathrm{Opt}$) que mide cuánto infla la fuga una métrica. Se evaluó sobre 96 pares de scripts con y sin fuga (6 datasets de scikit-learn, 4 familias de algoritmos y 4 tipos de fuga) y sobre 13 scripts escritos a mano como prueba independiente. El auditor acierta el 100 % del banco de control, que es una evaluación circular; en la prueba independiente el AST detecta 8 de 9 casos con fuga, la ejecución 7 de 9 y la combinación 9 de 9. El optimismo medido es casi nulo en clasificación (efecto techo) y de hasta 0,07 de R^2 en regresión; con señal nula la selección con fuga infla el AUC hasta 0,20. Los productos son dos Agent Skills y una plataforma web. Aún no se han generado pipelines con LLM reales; es el trabajo de Capstone II.

Para un público no técnico. Cuando una IA escribe un programa que aprende de datos, puede cometer un error silencioso: «espiar» los datos del examen mientras estudia, de modo que el resultado parece mejor de lo real. Este proyecto construye un revisor automático que encuentra ese error, lo corrige y calcula cuánto exageraba el resultado.

Palabras clave: fuga de datos; LLM; auditoría de código; scikit-learn; análisis estático; sesgo de optimismo.

ABSTRACT

LLM-based coding assistants already write end-to-end Machine Learning pipelines. Among their possible errors, data leakage is the only one that neither interrupts execution nor leaves evidence in the code, and it inflates evaluation metrics. This report presents a deterministic auditor that combines abstract syntax tree (AST) analysis with runtime verification, a refactoring tool that repairs common patterns without changing the model, and an Optimism Bias indicator ($\Delta\mathrm{Opt}$) that measures how much leakage inflates a metric. It was evaluated on 96 pairs of leaky and clean scripts (6 scikit-learn datasets, 4 algorithm families, 4 leakage types) and on 13 hand-written scripts as an independent test. The auditor scores 100 % on the control bank, which is a circular evaluation; on the independent test the AST detects 8 of 9 leaky cases, runtime verification 7 of 9, and their combination 9 of 9. Measured optimism is almost null in classification (ceiling effect) and up to 0.07 of R^2 in regression; with null signal, leaky feature selection inflates AUC by up to 0.20. The products are two Agent Skills and a web platform. No pipelines from real LLMs have been generated yet; this is the work planned for Capstone II.

Keywords: data leakage; LLM; code auditing; scikit-learn; static analysis; optimism bias.

Índice general

Resumen I
Abstract II

1. INTRODUCCIÓN Y FORMULACIÓN DEL PROBLEMA 1
1.1. Contexto 1
1.2. Qué es la fuga y cómo ocurre en scikit-learn 1
1.3. Problema, pregunta y relevancia 2
1.4. Objetivos 2
1.5. Métrica central y criterios de éxito 3
1.6. Alcance, supuestos y restricciones 3
1.7. Retroalimentación de la primera entrega 4

2. FUNDAMENTACIÓN Y POSICIONAMIENTO 5

3. METODOLOGÍA, DATOS Y PLAN DE TRABAJO 6
3.1. Metodología 6
3.2. Datos: origen, obtención y caracterización 6
3.3. Diseño experimental 7
3.4. Plan de trabajo actualizado y desviaciones 8

4. VALIDACIÓN, LÍNEA BASE Y RESULTADOS PRELIMINARES 9
4.1. Protocolo para evitar la fuga en la propia evaluación 9
4.2. Métricas y línea base 9
4.3. Resultados: eficacia del auditor 9
4.4. Resultados preliminares: Sesgo de Optimismo 10
4.5. Control positivo: cuándo la selección con fuga sí daña 11

5. INTERPRETACIÓN Y JUICIO CRÍTICO 13

6. APLICABILIDAD Y USO RESPONSABLE 15
6.1. Contexto de uso 15
6.2. Propuesta de implementación 15
6.3. Riesgos éticos y medidas 15

7. CONCLUSIONES 17

REFERENCIAS 18

ANEXO A. REPRODUCIBILIDAD Y REPOSITORIO 21

1. INTRODUCCIÓN Y FORMULACIÓN DEL PROBLEMA

1.1 Contexto

Los asistentes de programación basados en modelos de lenguaje grande (LLM) ya escriben pipelines completos de ciencia de datos (Hong et al., 2025), y los *benchmarks* de agentes miden su puntaje o su tasa de éxito (Chan et al., 2025; Huang et al., 2024), no la validez metodológica de lo que producen. Un código generado por un LLM puede fallar de siete formas habituales: (1) errores de sintaxis; (2) alucinación de APIs o uso de métodos obsoletos; (3) incompatibilidad de dimensiones o tipos; (4) ineficiencia o agotamiento de memoria; (5) falta de control de semillas; (6) manejo inseguro de archivos o credenciales; y (7) **fuga de datos** (*data leakage*).

La fuga es el único de los siete que **no interrumpe la ejecución**. Los fallos 1 a 4 y 6 producen una excepción o son visibles para un *linter*, y el fallo 5 se detecta repitiendo la corrida. En cambio, la fuga produce un script que corre de principio a fin, entrega métricas más altas y, por eso, rara vez se cuestiona (Tabla 1.1). En la práctica humana el problema es amplio: Kapoor y Narayanan (2023) hallaron 294 artículos afectados por fuga en 17 campos científicos, y Kaufman et al. (2012) la formularon como información del objetivo que no estaría disponible al predecir.

Tabla 1.1. *Fallos ruidosos frente a fallo silencioso en código de ML generado por LLM.*

Dimensión	Fallos ruidosos (1–4 y 6)	Fuga de datos (7)
Comportamiento del intérprete	Lanza una excepción	Se ejecuta sin error ni advertencia
Detección estándar	Intérprete o *linter*	Invisible para herramientas convencionales: tipos y dimensiones coinciden
Efecto sobre las métricas	No llega a producirlas	Las infla (optimismo)
Riesgo en producción	Bajo: el pipeline no corre	Alto: el modelo se despliega con una capacidad de generalización peor que la creída

1.2 Qué es la fuga y cómo ocurre en scikit-learn

Un transformador (escalador, imputador, selector de variables, PCA) *aprende* parámetros con `.fit()`: medias y desviaciones, vecinos más cercanos, o qué variables conservar. Si aprende con **todas** las filas antes de separar entrenamiento y prueba, o fuera de un `Pipeline` dentro de una validación cruzada, ya vio las filas que luego se usan para evaluar. Formalmente, el aislamiento correcto exige que los parámetros del preprocesamiento sean función solo de los datos de entrenamiento; hay fuga cuando algún parámetro se estima con la unión de entrenamiento y prueba. La Figura 1.1 contrasta ambas formas con el mismo modelo, los mismos datos y los mismos pliegues.

```
# CON FUGA: el escalador ve todas las filas
X_esc = StandardScaler().fit_transform(X)
scores = cross_val_score(modelo, X_esc, y, cv=5)

# SIN FUGA: en cada pliegue, .fit() ve solo el entrenamiento
pipe = Pipeline([("escalador", StandardScaler()), ("modelo", modelo)])
scores = cross_val_score(pipe, X, y, cv=5)
```

Figura 1.1. *Misma operación con y sin fuga de datos.*

Se estudian cuatro mecanismos: **escalado** (la media y la varianza incluyen filas de prueba), **imputación** (`KNNImputer` puede copiar valores de vecinos de prueba), **selección de variables** (`SelectKBest` usa las etiquetas de todas las filas) y **combinada** (los tres a la vez).

1.3 Problema, pregunta y relevancia

Problema. Un script de ML tabular puede contener fuga de datos sin que nada lo advierta, y quien recibe ese código de un asistente de IA no tiene una forma barata de comprobarlo ni de saber cuánto distorsiona la evaluación.

Pregunta de investigación. ¿Es posible detectar automáticamente, leyendo y ejecutando el código, la fuga de preprocesamiento y selección en pipelines de scikit-learn; reparar el código sin cambiar el modelo; y cuantificar cuánto optimismo introduce la fuga en distintas familias de algoritmos?

Relevancia. Los detectores existentes son principalmente estáticos y se evaluaron sobre código humano (AlOmar et al., 2025; Drobnjaković et al., 2024; Yang et al., 2022), y los LLM tienen dificultades para identificar por sí mismos estos problemas tempranos del pipeline (Kumar et al., 2025). Falta un instrumento determinista que audite código de asistentes, lo repare y mida el daño; ese es el entregable de este proyecto.

1.4 Objetivos

Objetivo general. Diseñar, validar empíricamente e implementar un marco automatizado de detección y prevención de fuga de datos en pipelines de aprendizaje supervisado con scikit-learn, y cuantificar el sesgo de optimismo que induce en cuatro familias de algoritmos.

Tabla 1.2. *Objetivos específicos verificables y evidencia.*

OE	Objetivo específico	Evidencia
OE1	Formalizar los mecanismos de fuga (escalado, imputación, selección, combinada) y distinguirlos de otros fallos de código generado.	Secciones 1.1–1.2; banco de 96 pares
OE2	Desarrollar un auditor determinista (AST y verificación en ejecución) y medir su precisión, recall y VPN contra una verdad conocida.	Tablas 4.1 y 4.2
OE3	Cuantificar el Sesgo de Optimismo $\Delta\mathrm{Opt}$ por tipo de fuga y familia (RandomForest, Gradient Boosting, lineal regularizado y red neuronal MLP) en 3 datasets de clasificación y 3 de regresión.	Tablas 4.3 y 4.4; Figuras 4.1 y 4.2
OE4	Entregar dos Agent Skills y una plataforma web que permitan auditar, reparar y crear pipelines sin fuga.	Capítulo 6

1.5 Métrica central y criterios de éxito

La métrica es el **Sesgo de Optimismo Inducido por Fuga**:

$$\Delta\mathrm{Opt} = M_{\mathrm{leaky}} - M_{\mathrm{clean}}, \tag{1.1}$$

donde M es el promedio de una métrica (ROC-AUC, F1, R^2 o $-$RMSE) en 5 pliegues, y M_{leaky} y M_{clean} provienen del mismo dataset, los mismos pliegues (semilla 42), el mismo modelo y los mismos hiperparámetros: solo cambia si el preprocesamiento se ajustó con todas las filas o dentro de un `Pipeline`. Por construcción, si no hay fuga, $\Delta\mathrm{Opt} = 0$. Se evita el nombre «brecha de generalización», que en el aprendizaje estadístico clásico designa la diferencia entre el desempeño de entrenamiento y el de prueba, es decir, el sobreajuste, que puede ser alto incluso sin fuga (por ejemplo, un árbol sin poda).

Donde: $\Delta\mathrm{Opt}$: sesgo de optimismo; M_{leaky}: métrica promedio del pipeline con fuga; M_{clean}: métrica promedio del mismo pipeline sin fuga (preprocesamiento dentro de un `Pipeline`); un valor positivo indica que la fuga mejora artificialmente la métrica.

Tabla 1.3. *Criterios de éxito operativos y resultado (detalle en los capítulos 4 y 5).*

OE	Criterio (umbral o punto de comparación)	Resultado
OE2	Banco de control: precisión y recall $\geq 0{,}90$	1,00 y 1,00 (evaluación **circular**, ver sección 4.3)
OE2	Evaluación independiente (13 scripts manuales): recall híbrido $\geq 0{,}80$ y 0 falsos positivos	9/9 y 0 FP; IC95 % exacto del recall [0,66; 1,00]: **con** $n = 9$ **no se puede afirmar** el umbral
OE3	H-esc.: en árboles, $\Delta\mathrm{Opt}$ por escalado ≈ 0 ($\lvert\Delta\mathrm{Opt}\rvert < 0{,}001$)	Confirmada: máximo 0,0002
OE3	H-MLP: la red neuronal sufre el mayor $\Delta\mathrm{Opt}$	**Parcial**: solo en regresión y sin significancia tras corregir por multiplicidad
OE4	Reparación automática ≥ 90 % de los scripts con fuga	96/96 en el banco; **4/9** en la evaluación independiente

Nota. H-esc.: hipótesis del escalado en árboles; H-MLP: hipótesis de mayor vulnerabilidad de la red neuronal; FP: falsos positivos. Los umbrales son propuestas del autor, formalizadas después de la prueba piloto descrita aquí; en Capstone II se fijarán antes de evaluar con pipelines de LLM reales.

1.6 Alcance, supuestos y restricciones

Alcance: clasificación y regresión supervisadas con scikit-learn sobre datos tabulares; fuga de preprocesamiento, imputación y selección de variables. El *clustering* queda fuera porque no hay un objetivo explícito contra el cual medir el optimismo. *Supuestos:* datos i.i.d.; 5 pliegues con semilla fija; el generador de pares reproduce con fidelidad el mecanismo de fuga. *Restricciones:* solo datasets nativos de scikit-learn y sin anotadores humanos (observaciones del comité); no se auditan fugas temporales ni de dominio; los pipelines escritos por LLM reales **aún no se han generado** (Capstone II).

1.7 Retroalimentación de la primera entrega

La Tabla 1.4 resume las observaciones recibidas en la primera entrega y dónde se incorporó cada una en este informe.

Tabla 1.4. *Observaciones de la primera entrega y su incorporación.*

N.º	Observación	Dónde se incorpora
1	Contextualizar los problemas de los LLM y justificar la fuga	Sección 1.1, Tabla 1.1
2	Aclarar qué modelos generan y cuáles auditan	Sección 3.3: el auditor es determinista; los LLM serán solo sujetos de estudio
3	Mostrar cómo se fugan los datos, con un ejemplo	Sección 1.2, Figura 1.1
4	Explicar el experimento paso a paso	Sección 3.3 y Anexo A
5	Usar datasets de scikit-learn y evitar anotadores humanos	Sección 3.2; verdad conocida por construcción
6	Acotar el paradigma y las familias de modelos	Secciones 1.6 y 3.3
7	Dejar todo disponible en un repositorio y poder explicar el código	Anexo A
8	Entregar como producto final una o varias *Skills*	Objetivo OE4 y capítulo 6
9	Validar la métrica («brecha de generalización auditada»)	Sección 1.5: se sustituye por $\Delta\mathrm{Opt}$

2. FUNDAMENTACIÓN Y POSICIONAMIENTO

La literatura se organiza en tres enfoques, que se comparan en la Tabla 2.1.

Detectores estáticos. Yang et al. (2022) analizan el flujo de datos de notebooks para detectar patrones de fuga; Drobnjaković et al. (2024) lo formalizan con interpretación abstracta; AlOmar et al. (2025) lo llevan a una extensión de IDE. Son deterministas y reproducibles, pero ciegos a lo que depende de los valores de los datos, y se validaron sobre código humano.

LLM como detector o juez. Draoui et al. (2026) combinan *slicing* estático con *prompts* estructurados a un LLM, y Nam et al. (2025) incorporan un agente de chequeo de fuga dentro de un agente de ingeniería de ML. El LLM como juez tiene sesgos documentados (Zheng et al., 2023) y no es reproducible, lo que lo hace inadecuado como instrumento de medición.

Buenas prácticas. Lones (2024) y Kapoor y Narayanan (2023) catalogan la fuga y recomiendan encapsular el preprocesamiento; ese es el criterio de «código correcto» que usa este proyecto.

Tabla 2.1. *Enfoques existentes y posicionamiento del proyecto.*

Enfoque	Detecta	Mide el efecto sobre la métrica	Repara el código	Limitación principal
Detectores estáticos	Patrones de flujo de datos	No	No	Ciegos a fuga dependiente de valores; validados en código humano
LLM como detector o juez	Lo descrito en el *prompt*	No	A veces	Sesgos y variabilidad; sin evidencia trazable
Este proyecto	AST y conteo de filas en `.fit`	**Sí** ($\Delta\mathrm{Opt}$, mismo pliegue)	**Sí** (patrones CV y Split)	Solo scikit-learn y tabular; alcance limitado de la reparación

Brecha y decisiones de diseño. Entre las fuentes revisadas, ninguna mide el optimismo con una intervención pareada ni combina lectura y ejecución del código con reparación. De allí se derivan cuatro decisiones: (i) el **detector es determinista**, no un LLM, porque se usa como instrumento de medición y debe ser reproducible (Zheng et al., 2023); (ii) se combinan **AST y verificación en ejecución**, porque el primero lee el código pero no sus valores y el segundo observa lo que ocurrió; (iii) $\Delta\mathrm{Opt}$ **pareado** sigue la práctica de comparar una evaluación defectuosa con la corregida (Cawley & Talbot, 2010; Kapoor & Narayanan, 2023); (iv) la comparación entre familias usa pruebas no paramétricas pareadas (Demšar, 2006), porque con pocos datasets no se justifica asumir normalidad.

3. METODOLOGÍA, DATOS Y PLAN DE TRABAJO

3.1 Metodología

Se adapta CRISP-DM a un problema de construcción de un instrumento de medición (Tabla 3.1); el diseño sigue la lógica de *design science*: construir un artefacto y evaluarlo contra una verdad conocida (Hevner et al., 2004).

Tabla 3.1. *Etapas, propósito y evidencia en el repositorio.*

Etapa (CRISP-DM adaptado)	Propósito	Objetivo	Archivo
Comprensión del problema	Fijar mecanismos de fuga y métrica	OE1	Capítulo 1; `decision_log.md`
Comprensión de los datos	Caracterizar los 6 datasets	OE3	`eda_datasets.py`
Preparación	Ruido, faltantes y submuestreo reproducibles	OE3	`sklearn_loader.py`
Modelado (del instrumento)	Generar los 96 pares; construir el auditor	OE2	`generar_pares_controlados.py`; `03_auditor/`
Evaluación	Precisión, recall, VPN, $\Delta\mathrm{Opt}$ y pruebas por familia	OE2, OE3	`run_benchmark.py`; `statistical_analysis.py`
Despliegue	Skills y plataforma web	OE4	`05_skills/`; `06_web/`

Donde: VPN: valor predictivo negativo; OE: objetivo específico.

3.2 Datos: origen, obtención y caracterización

Se usan seis conjuntos nativos de scikit-learn (Tabla 3.2): tres de clasificación (`breast_cancer`, `wine`, `digits`) y tres de regresión (`diabetes`, `california_housing`, `make_friedman1`). Son públicos, no contienen datos personales y se cargan sin copiarlos al repositorio; solo `california_housing` se descarga la primera vez. La Figura 3.1 resume la dispersión de escalas y el balance de clases.

Tabla 3.2. *Caracterización de los datasets.*

ID	Dataset	Tarea	N	Variables	Razón de escalas	Asimetría media	Clase minoritaria
D1	breast_cancer	Clasif. (2)	569	30	215.171	1,74	37,3 %
D2	wine	Clasif. (3)	178	13	2.530	0,43	27,0 %
D3	digits	Clasif. (10)	1.797	64	277	4,89	9,7 %
D4	diabetes	Regresión	442	10	1,0	0,41	—
D5	california_housing	Regresión	3.000*	8	1.398	10,00	—
D6	friedman1	Regresión	1.000	50	1,1	0,04	—

Nota. Razón de escalas: desviación estándar máxima sobre mínima entre variables. *Submuestra determinista de 3.000 filas de 20.640 (desviación B1, sección 3.4). `digits` tiene 3 columnas constantes.

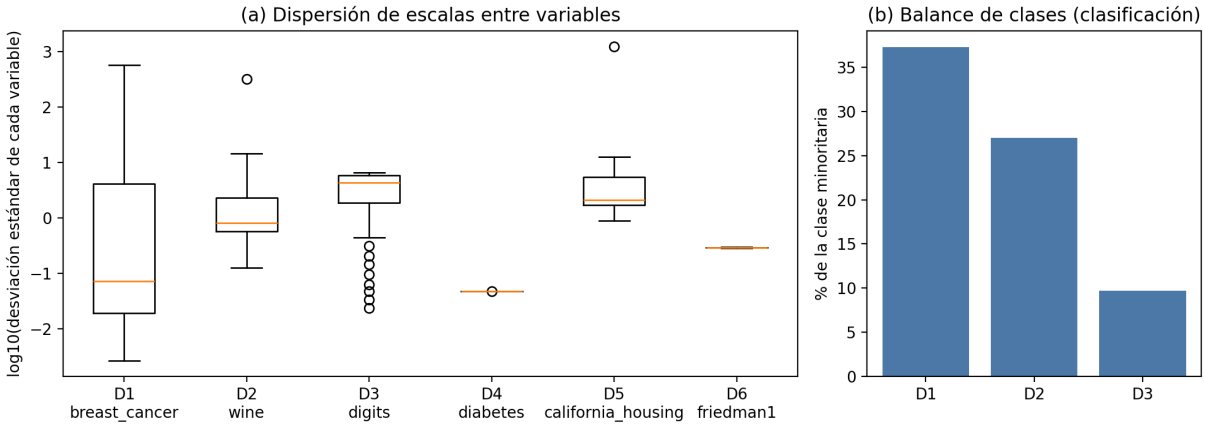


Figura 3.1. *(a) Dispersión de escalas entre variables, en* $\log_{10}$ *de la desviación estándar. (b) Porcentaje de la clase minoritaria en los datasets de clasificación.*

Preparación trazable. (i) *Variante «completo»*: sin faltantes. (ii) *Variante «con_faltantes»*: se borra el 10 % de las celdas con semilla fija (media observada entre 9,8 y 10,1 %). (iii) A D1–D5 se les agregan 50 columnas de ruido gaussiano, porque la fuga por selección solo se manifiesta si hay variables inútiles entre las cuales elegir; D6 ya trae 45. Todo usa la semilla 42, y dos ejecuciones producen datos idénticos (verificado en las pruebas automáticas).

Representatividad y limitaciones. Son datasets clásicos, limpios, pequeños y tabulares; no representan datos reales ruidosos, de gran escala ni con estructura temporal o jerárquica, y los LLM probablemente los vieron durante su entrenamiento. Por la dispersión de escalas (Figura 3.1a), el escalado debería afectar sobre todo a los modelos sensibles a la escala; por la asimetría de D5 (10,0) se esperan valores atípicos que desestabilicen a la red neuronal, y así ocurrió (sección 3.4). Con ROC-AUC cercana a 1 en D1–D3 hay un efecto techo que limita cuánto optimismo puede observarse en clasificación.

3.3 Diseño experimental

Para cada combinación de 6 datasets × 4 familias × 4 tipos de fuga, un generador escribe un script con fuga (`leaky`) y otro idéntico sin ella (`clean`): **96 pares, 192 scripts**. Los modelos son `RandomForest`, `HistGradientBoosting`, `LogisticRegression` o `Ridge`, y `MLPClassifier` o `MLPRegressor`. Como la verdad se conoce por construcción, no se necesitan anotadores.

Cada script se audita con **dos mecanismos independientes**. El primero es un análisis del árbol sintáctico (`ast`) con tres reglas: *R-Split* (ajuste antes de `train_test_split`), *R-CV* (ajuste fuera de un `Pipeline` cuyo resultado entra a la validación cruzada) y *R-Test* (ajuste con una variable que parece de prueba). El segundo es un verificador en ejecución que cuenta con cuántas filas se ajusta cada transformador y declara fuga si coincide con el total del dataset. El detector híbrido declara fuga si cualquiera de los dos la ve. El auditor nunca consulta a un LLM; los LLM serán solo los sujetos de estudio que generan los pipelines en Capstone II.

3.4 Plan de trabajo actualizado y desviaciones

Tabla 3.3. *Plan de trabajo (estado a octubre de 2026).*

Periodo	Actividad	Estado
Capstone I	Reformulación del problema y la métrica; datasets; banco de 96 pares; auditor AST y runtime; refactorizador; benchmark y $\Delta\mathrm{Opt}$; Skills y plataforma web (prototipo); informe	Hecho
Capstone II, sem. 1–4	Generar pipelines con 6–8 LLM reales (24 tareas por modelo) y auditarlos; ejecutarlos en un entorno aislado	Pendiente
Capstone II, sem. 5–8	Mejorar el auditor (alias de importación, funciones auxiliares, `ColumnTransformer`); ampliar la evaluación independiente de 13 a ≥ 60 scripts	Pendiente
Capstone II, sem. 9–12	Más datasets con señal débil; intervalos bootstrap por dataset; piloto de uso con 3–5 personas	Pendiente
Capstone II, sem. 13–16	Redacción de la tesis y defensa	Pendiente

Desviaciones respecto del plan original (justificación completa en `07_informe/decision_log.md`):

- **B1.** `california_housing` se submuestrea a 3.000 filas: `KNNImputer` crece con n^2 y el banco de 192 scripts no sería ejecutable en un portátil.
- **B2.** El sobremuestreo (SMOTE) no se mide, porque no pertenece a scikit-learn; el cuarto tipo es «combinada».
- **B3.** `LogisticRegression` usa `max_iter=2000` para evitar avisos de no convergencia.
- **C1.** En una primera corrida, los modelos lineal y MLP se evaluaban sin escalar en las fugas de imputación y selección, lo que producía diferencias negativas por inestabilidad numérica (hasta $-0{,}155$ en `wine`). Se corrigió añadiendo un escalador interno idéntico en ambas versiones; los resultados descartados se conservan en `results/corrida1_descartada/`.
- **C2.** Un `MLPRegressor` divergió en un pliegue ($R^2 = -21$ en `california_housing`; promedio $-3{,}86$). Se definió, **después de ver el problema**, que un par es degenerado si algún pliegue tiene $R^2 < -1$; se excluyó 1 par de 96 y se lista aparte.

4. VALIDACIÓN, LÍNEA BASE Y RESULTADOS PRELIMINARES

4.1 Protocolo para evitar la fuga en la propia evaluación

Se aplica al experimento lo que se audita: (i) validación cruzada de 5 pliegues (estratificada en clasificación) con semilla 42 y los **mismos pliegues** para `leaky` y `clean`; (ii) en la versión `clean` y en el código reparado, todo el preprocesamiento va dentro de un `Pipeline`, de modo que se ajusta solo con el entrenamiento de cada pliegue; (iii) el verificador en ejecución comprueba que, en `clean`, ningún transformador vea tantas filas como el total (el máximo observado es 80,3 %); (iv) las pruebas estadísticas usan como unidad el **par** (dataset $\times$ tipo de fuga) y no los pliegues, que no son independientes.

4.2 Métricas y línea base

Del auditor (positivo = «hay fuga»): precisión, recall, F1 y valor predictivo negativo (VPN: probabilidad de que un script declarado limpio lo sea). *Del daño*: $\Delta\mathrm{Opt}$ en ROC-AUC (clasificación) y R^2 (regresión), con F1 macro y RMSE como secundarias. *Línea base:* el pipeline `clean` es el punto de comparación de $\Delta\mathrm{Opt}$, y los componentes por separado (solo AST y solo ejecución) son la línea base del detector híbrido. No se comparó contra un *linter* ni contra un LLM juez; queda para Capstone II.

4.3 Resultados: eficacia del auditor

Tabla 4.1. *Banco de control: 192 scripts con verdad conocida.*

Detector	TP	TN	FP	FN	Precisión	Recall	VPN
AST (estático)	96	96	0	0	1,00	1,00	1,00
Ejecución	96	96	0	0	1,00	1,00	1,00
Híbrido	96	96	0	0	1,00	1,00	1,00

Donde: TP, TN, FP, FN: verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos; $\mathrm{Precisión} = TP/(TP+FP)$; $\mathrm{Recall} = TP/(TP+FN)$; $\mathrm{VPN} = TN/(TN+FN)$.

Este 100 % no prueba que el auditor generalice: el banco lo produce un generador escrito por el mismo autor que el auditor (evaluación circular), con patrones que este conoce. Por eso se añadió una **evaluación independiente** con 13 scripts escritos a mano (9 con fuga y 4 limpios), con estilos que el generador no produce: `make_pipeline`, DataFrames, funciones auxiliares, alias de importación, variables `X_te`, y `fit` y `transform` por separado.

Tabla 4.2. *Evaluación independiente ($n = 13$).*

Detector	TP	TN	FP	FN	Precisión	Recall	VPN
AST	8	4	0	1	1,00	0,89	0,80
Ejecución	7	4	0	2	1,00	0,78	0,67
Híbrido	9	4	0	0	1,00	1,00	1,00

El AST falla con el alias de importación (`StandardScaler as SS`); la ejecución falla con ajustes que no usan todas las filas (el escalador re-ajustado solo con las filas de prueba, y el ajustado con el 70 % de entrenamiento antes de la validación cruzada). Fallan en casos distintos, lo que respalda el diseño híbrido. Con $n = 13$, estas cifras son una **señal**, no una estimación estable. La reparación automática resolvió 4 de los 9 scripts con fuga; en los otros 5 declaró «requiere revisión manual» y no tocó el código.

4.4 Resultados preliminares: Sesgo de Optimismo

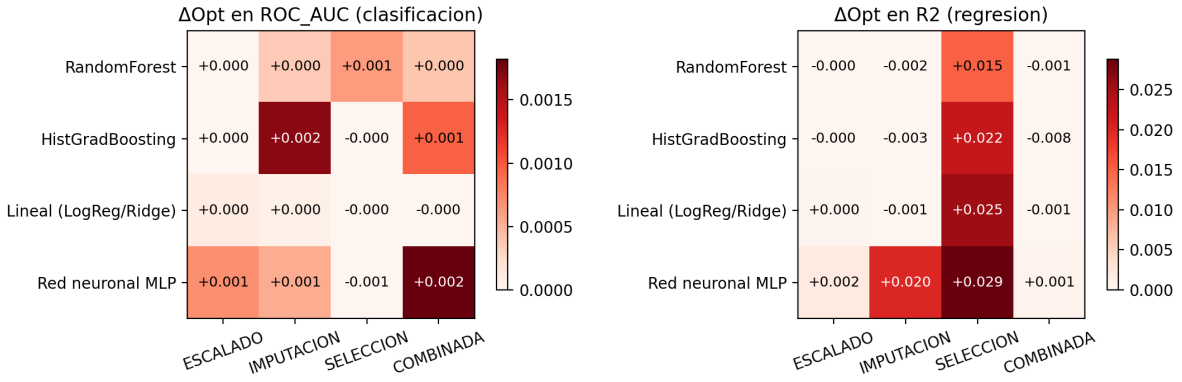


Figura 4.1. $\Delta\mathrm{Opt}$ *medio por familia y tipo de fuga (ROC-AUC en clasificación, R^2 en regresión). El par degenerado (D5, MLP, combinada) está excluido.*

Tabla 4.3. $\Delta\mathrm{Opt}$ *medio, promedio sobre los datasets.*

Tarea	Familia	Escalado	Imputación	Selección	Combinada
Clasificación (AUC)	RandomForest	0,0000	0,0004	0,0006	0,0004
	Gradient Boosting	0,0000	0,0017	$-0{,}0001$	0,0010
	Lineal	0,0001	0,0001	$-0{,}0001$	0,0000
	MLP	0,0007	0,0005	$-0{,}0009$	0,0018
Regresión (R^2)	RandomForest	$-0{,}0001$	$-0{,}0024$	0,0150	$-0{,}0014$
	Gradient Boosting	0,0000	$-0{,}0033$	0,0220	$-0{,}0082$
	Lineal	0,0001	$-0{,}0008$	0,0255	$-0{,}0007$
	MLP	0,0019	0,0200	0,0288	0,0006*

Nota. *Media de 2 datasets (se excluyó el par degenerado).

Se observan tres hechos. **(1) En clasificación, $\Delta\mathrm{Opt}$ es prácticamente nulo**: en 48 pares va de $-0{,}0027$ a $+0{,}0034$, con un AUC limpio mediano de 0,991 (efecto techo). **(2) En regresión aparece optimismo, concentrado en la selección con `california_housing`**: R^2 de 0,690 (sin fuga) frente a 0,731 (con fuga) en RandomForest, y de 0,615 frente a 0,689 en MLP; en los 47 pares el rango es de $-0{,}023$ a $+0{,}074$. **(3) Escalado y árboles:** en RandomForest y HistGradientBoosting, en los 6 datasets, el máximo $|\Delta\mathrm{Opt}|$ por escalado es 0,0002, como predice la teoría: una transformación afín creciente no cambia la estructura de un árbol.

Tabla 4.4. *Pruebas por familia en regresión (fugas simples, $n = 9$ pares).*

Familia	$\Delta\mathrm{Opt}$ medio	d de Cohen	p Wilcoxon (unilateral)	p t pareada
RandomForest	0,0042	0,29	0,320	0,203
Gradient Boosting	0,0062	0,32	0,371	0,183
Lineal (Ridge)	0,0083	0,34	0,285	0,168
MLP	0,0169	0,65	**0,037**	**0,044**

Nota. Hipótesis alternativa: $\Delta\mathrm{Opt} > 0$. Se usan las fugas simples (escalado, imputación y selección) porque la combinada repite esos mecanismos.

En clasificación, el p de Wilcoxon de todas las familias es $\geq 0{,}148$. La prueba de Friedman entre familias da $p = 0{,}84$ en clasificación y $p = 0{,}041$ en regresión (rangos medios, donde 1 indica el mayor optimismo: RandomForest 3,39; Gradient Boosting 2,72; Lineal 2,11; MLP 1,78). **Estos valores p no están corregidos por multiplicidad**: con 8 pruebas por familia, el umbral de Holm para la más pequeña es $0{,}05/8 = 0{,}006$, que el 0,037 no alcanza, y con 2 pruebas de Friedman el umbral de Bonferroni es 0,025, que el 0,041 tampoco alcanza. Se reportan como **exploratorios** (véase Demšar, 2006).

4.5 Control positivo: cuándo la selección con fuga sí daña

Como la selección apenas inflaba el AUC, se midió si $\Delta\mathrm{Opt}$ detecta la fuga cuando esta debería importar. Se repitió solo la selección con 0, 50, 200 y 1000 columnas de ruido, en dos escenarios: *real* (etiquetas verdaderas) y *señal nula* (etiquetas permutadas al azar, de modo que la verdad es AUC $= 0{,}5$ y $R^2 \leq 0$).

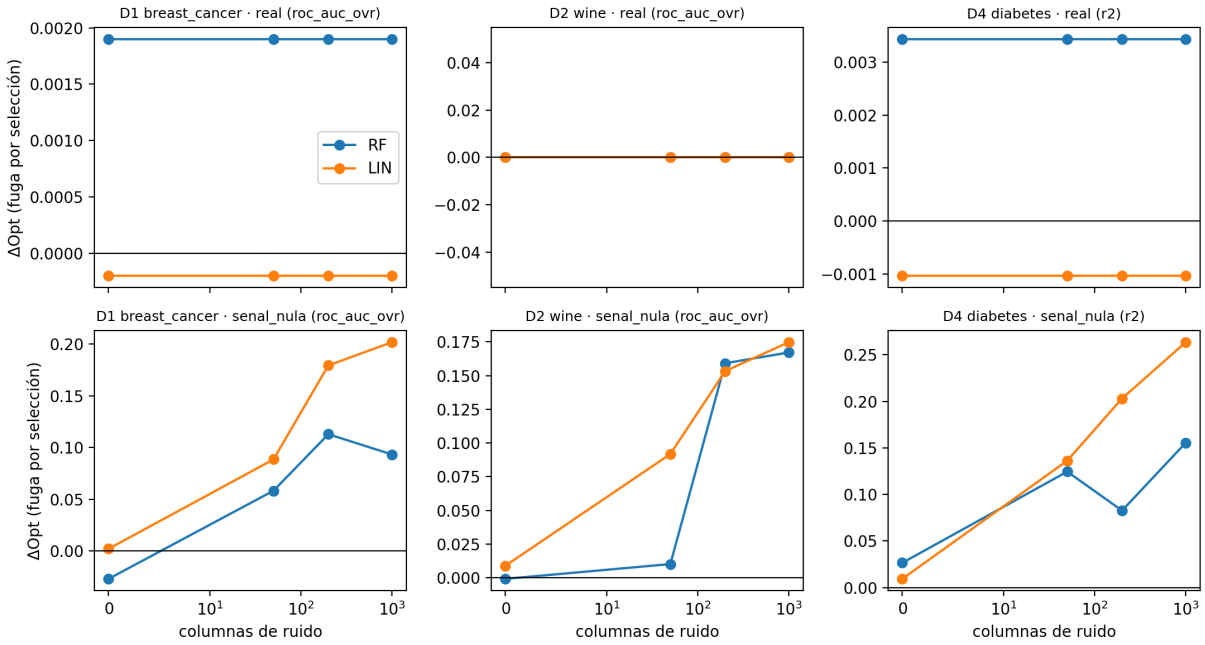


Figura 4.2. $\Delta\mathrm{Opt}$ *de la selección con fuga según el número de columnas de ruido. Fila superior: etiquetas reales. Fila inferior: señal nula (control positivo).*

Con etiquetas reales, $\Delta\mathrm{Opt}$ **no cambia** con el ruido (por ejemplo, `breast_cancer` con RandomForest: 0,0019 en los cuatro niveles), porque con al menos 8 variables muy informativas el selector nunca elige columnas de ruido. Con señal nula crece con el ruido hasta $+0{,}20$ **de AUC** (`breast_cancer`, lineal, 1000 columnas) y $+0{,}26$ **de** R^2 (`diabetes`, lineal): el selector «encuentra» columnas de ruido que, por azar, parecen predecir.

5. INTERPRETACIÓN Y JUICIO CRÍTICO

Qué indican los resultados. (a) El auditor reconoce con fiabilidad los patrones para los que fue diseñado, pero el 100 % del banco **no** es evidencia de generalización: la prueba independiente baja el recall del AST a 0,89 y el del verificador a 0,78, y cada uno falla donde el otro acierta. La conclusión sostenible es que **la combinación es más robusta que cada parte**, no que el auditor sea casi perfecto. (b) La fuga de preprocesamiento y selección tuvo un efecto pequeño en los datasets elegidos, no porque sea inocua sino porque estos datos son «fáciles»: señal fuerte y AUC en el techo. El control positivo muestra que, cuando la señal es débil frente al ruido, el mismo mecanismo infla la métrica hasta 0,20–0,26; la gravedad depende de la relación entre señal y ruido y no es una propiedad fija de cada tipo de fuga ni de cada familia de modelos. (c) De las dos hipótesis de la reformulación, la del escalado en árboles se confirma con claridad; la de que la red neuronal es la más vulnerable tiene respaldo débil: se observa en regresión ($\Delta\mathrm{Opt}$ medio 0,017; $d = 0{,}65$) pero no en clasificación, y no resiste la corrección por multiplicidad.

Implicaciones para la factibilidad. El proyecto es factible como instrumento (detectar, reparar y medir) y se puede defender con lo hecho. Es menos sólido como afirmación empírica sobre «qué modelos sufren más», porque hay solo 3 datasets por tarea y 9 pares por familia. Por eso el objetivo OE3 se reformula para Capstone II: estimar $\Delta\mathrm{Opt}$ **condicionado a la razón señal/ruido**, y no como un número único por familia.

Limitaciones y amenazas a la validez. *Datos:* seis datasets clásicos que los LLM probablemente conocen, un submuestreo de `california_housing` y un efecto techo en clasificación. *Método:* el generador y el auditor tienen el mismo autor (circularidad), la prueba independiente tiene 13 casos, la exclusión de un par degenerado fue posterior a ver el problema y los valores p no están corregidos. *Generalización:* los resultados valen para pipelines sintéticos de scikit-learn; **aún no se sabe qué tan frecuente es la fuga en código escrito por LLM reales**, que es la pregunta motivadora del proyecto, ni cómo se comporta el auditor ante su variedad de estilos.

Riesgos para Capstone II y ajustes propuestos. La Tabla 5.1 los resume junto con la evidencia que los respalda.

Tabla 5.1. *Riesgos observados, evidencia y ajustes para Capstone II.*

Riesgo	Evidencia	Ajuste
El código de LLM reales es más variado que las plantillas y el recall caerá	AST 0,89 y ejecución 0,78 en código escrito a mano	Ampliar la prueba independiente a ≥ 60 scripts y, con los LLM reales, etiquetar una muestra a mano con revisión cruzada
Alias, funciones auxiliares y reparaciones manuales (solo 4/9 reparados)	Un caso con alias; cuatro casos sin reparación automática	Resolver alias de importación; ampliar el refactorizador a `ColumnTransformer` y funciones
Efecto techo y pocos datasets	AUC mediano 0,991; $\lvert\Delta\mathrm{Opt}\rvert \leq 0{,}0034$ en clasificación	Incorporar datasets de señal débil o con muchas más variables que filas; informar $\Delta\mathrm{Opt}$ por tramo de señal/ruido
Ejecutar código de LLM es riesgoso	—	Ejecutar solo en contenedor sin red ni credenciales; la plataforma web seguirá sin ejecutar código
Costo y términos de servicio de las APIs	Script de generación sin probar	Medir tokens con 2 modelos antes de escalar; revisar términos de publicación de salidas

6. APLICABILIDAD Y USO RESPONSABLE

6.1 Contexto de uso

Los usuarios previstos son (1) analistas y estudiantes de ciencia de datos que reciben pipelines de un asistente de IA y (2) equipos que quieren una revisión automática antes de integrar código a un repositorio. La decisión que informa el auditor es: *aceptar, corregir o derivar a revisión humana* un pipeline.

6.2 Propuesta de implementación

Se ofrecen dos vías equivalentes, que comparten el mismo auditor.

- **Skills para agentes** (`05_skills/`). `audit-ml-leakage` audita y repara scripts existentes; `create-leakage-free-pipeline` impone reglas obligatorias al crear código (todo preprocesamiento dentro de un `Pipeline`, prueba final apartada, semillas fijas) y exige autoverificación con el auditor antes de entregar. Cada Skill es una carpeta autocontenida que se copia al directorio de Skills del agente.
- **Plataforma web** (`06_web/`, Streamlit). El usuario pega o sube un `.py`, ve las líneas con fuga, descarga el código corregido y consulta los resultados del experimento. Está pensada para quienes no usan agentes y **no ejecuta el código**: solo lo lee.
- **Integración continua.** La herramienta de línea de comandos devuelve código de salida 0 (limpio) o 1 (fuga), por lo que puede bloquear una integración.

Requisitos: Python (probado con la versión 3.13) y scikit-learn. *Condiciones de uso:* scripts tabulares con scikit-learn; los notebooks se exportan a `.py`. *Monitoreo:* registrar los falsos negativos que reporten los usuarios y usarlos para ampliar las reglas. *Verificación hecha:* 37 pruebas automáticas, incluida la comprobación de que la plataforma web arranca sin errores. **Aún no se ha hecho una prueba de uso con personas**; el producto es un prototipo y esa prueba queda para Capstone II.

6.3 Riesgos éticos y medidas

- **Falsa seguridad.** Un resultado «0 fugas detectadas» no significa «sin fuga»: no se ven fugas temporales, de dominio ni por duplicados, ni código dinámico. La plataforma y las Skills lo declaran en pantalla y en sus instrucciones.
- **Datos.** No se usan datos personales. `breast_cancer` y `diabetes` son conjuntos clínicos públicos y anonimizados que se emplean solo con fines metodológicos, sin ninguna intención de uso clínico.
- **Seguridad.** El banco ejecuta solo código generado por el propio proyecto; el código de LLM reales se ejecutará únicamente en entornos aislados.
- **Sesgo.** No se evalúa equidad porque no es el objeto del estudio; se declara como límite.
- **Términos de servicio.** Se revisarán los de las APIs de LLM antes de publicar salidas generadas.

- **Uso de IA. [COMPLETAR según la política del programa: indicar qué partes se redactaron o programaron con asistencia de IA y que el autor las revisó y puede explicarlas.]**

7. CONCLUSIONES

Se construyó un instrumento determinista que detecta fuga de preprocesamiento y selección en scripts de scikit-learn, la repara en los patrones habituales y mide su efecto con un indicador pareado ($\Delta\mathrm{Opt}$) que separa la fuga del sobreajuste. Funciona perfectamente sobre un banco de control propio y, en una prueba independiente pequeña, el diseño híbrido detectó los 9 casos con fuga, aunque ninguno de sus dos componentes lo logra solo. El efecto medido sobre las métricas fue pequeño con datos de señal fuerte y grande con señal débil, lo que obliga a reformular el objetivo OE3 en términos de señal y ruido. Queda pendiente, y es lo que da sentido al proyecto, medir la fuga en código de LLM reales. Las cifras y el código están en el repositorio y se regeneran con un solo comando.

REFERENCIAS

AlOmar, E. A., DeMario, C., Shagawat, R., & Kreiser, B. (2025). LeakageDetector: An open source data leakage analysis tool in machine learning pipelines. *2025 IEEE International Conference on Software Analysis, Evolution and Reengineering (SANER)*, 844–849. https://doi.org/10.1109/SANER64311.2025.00089

Cawley, G. C., & Talbot, N. L. C. (2010). On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research*, *11*, 2079–2107.

Chan, J. S., Chowdhury, N., Jaffe, O., Aung, J., Sherburn, D., Mays, E., Starace, G., Liu, K., Maksin, L., Patwardhan, T., Weng, L., & Mądry, A. (2025). MLE-bench: Evaluating machine learning agents on machine learning engineering. *The Thirteenth International Conference on Learning Representations (ICLR 2025)*. https://openreview.net/forum?id=6s5uXNWGIh

Demšar, J. (2006). Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, *7*, 1–30.

Draoui, T., Mkaouer, M. W., & Newman, C. (2026). Improving data leakage detection in machine learning notebooks through static slicing and structured LLM prompts. *Proceedings of the ACM on Software Engineering*, *3*(FSE), 4371–4392. https://doi.org/10.1145/3808199

Drobnjaković, F., Subotić, P., & Urban, C. (2024). An abstract interpretation-based data leakage static analysis. *Theoretical Aspects of Software Engineering (TASE 2024)*, *14777*, 109–126. https://doi.org/10.1007/978-3-031-64626-3_7

Hevner, A. R., March, S. T., Park, J., & Ram, S. (2004). Design science in information systems research. *MIS Quarterly*, *28*(1), 75–105. https://doi.org/10.2307/25148625

Hong, S., Lin, Y., Liu, B., Liu, B., Wu, B., Zhang, C., Li, D., Chen, J., Zhang, J., Wang, J., Zhang, L., Zhang, L., Yang, M., Zhuge, M., Guo, T., Zhou, T., Tao, W., Tang, R., et al. (2025). Data Interpreter: An LLM agent for data science. *Findings of the Association for Computational Linguistics: ACL 2025*, 19796–19821. https://doi.org/10.18653/v1/2025.findings-acl.1016

Huang, Q., Vora, J., Liang, P., & Leskovec, J. (2024). MLAgentBench: Evaluating language agents on machine learning experimentation. *Proceedings of the 41st International Conference on Machine Learning (PMLR 235)*, 20271–20309. https://proceedings.mlr.press/v235/huang24y.html

Kapoor, S., & Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, *4*(9), Artículo 100804. https://doi.org/10.1016/j.patter.2023.100804

Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, *6*(4), Artículo 15. https://doi.org/10.1145/2382577.2382579

Kumar, S., Lones, M. A., Maarek, M., & Zantout, H. (2025). *Navigating pitfalls: Evaluating LLMs in machine learning programming education*. arXiv. https://doi.org/10.48550/arXiv.2505.18220

Lones, M. A. (2024). Avoiding common machine learning pitfalls. *Patterns*, *5*(10), Artículo 101046. https://doi.org/10.1016/j.patter.2024.101046

Nam, J., Yoon, J., Chen, J., Shin, J., Arık, S. Ö., & Pfister, T. (2025). MLE-STAR: Machine learning engineering agent via search and targeted refinement. *Advances in Neural Information Processing Systems 38 (NeurIPS 2025)*, 129290–129310. https://doi.org/10.52202/085713-3889

Yang, C., Brower-Sinning, R. A., Lewis, G., & Kästner, C. (2022). Data leakage in notebooks: Static detection and better processes. *Proceedings of the 37th IEEE/ACM International Conference on Automated Software Engineering (ASE 2022)*, 1–12. https://doi.org/10.1145/3551349.3556918

Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing, E. P., Zhang, H., Gonzalez, J. E., & Stoica, I. (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. *Advances in Neural Information Processing Systems 36 (NeurIPS 2023), Datasets and Benchmarks Track*, 46595–46623. https://doi.org/10.52202/075280-2020

ANEXOS

ANEXO A. REPRODUCIBILIDAD Y REPOSITORIO

Repositorio: https://github.com/witman92/ml-leakage-auditor-capstone.

Todas las tablas y figuras de este informe se generan en `04_experiments/results/` y se reproducen con:

```
pip install -r requirements.txt
python ejecutar_todo.py          # 192 scripts, estadistica, figuras y 37 pruebas
streamlit run 06_web/app.py      # plataforma web
```

La carpeta del proyecto se abre en VS Code con `capstone.code-workspace`; cada paso del experimento tiene una tarea asociada. El detalle de decisiones y desviaciones está en `07_informe/decision_log.md`.